

数据挖掘课程项目中期进展报告

基于多源异构数据整合的“双一流”高校高层次人才梯队分析

王智鹏、熊梓任、陈丁搏、徐政陽、胡玄哲

2026 年 6 月 1 日

1 项目基本信息

- 项目名称：基于多源异构数据整合的“双一流”高校高层次人才梯队分析
- 项目方向：复杂 Data-Centric 改进
- 项目链接：https://github.com/HUX3273/Data_Mining_2026
- 中期报告定位：围绕开题报告提出的“多源异构、高冲突、高缺失”人才数据整合问题，汇报数据采集、审计、融合、指标构建与初步建模分析的阶段性进展。

姓名	学号	组内角色	开题以来的核心贡献	中期之后的分工规划
王智鹏	3120255027	建模与报告整合	负责建模方案设计，整理 K-Means/回归分析思路，统筹中期报告结构	完成聚类模型调优、实验结果解释、终版报告和答辩 PPT 整合
熊梓任	3120250948	EDA 与可视化	负责人才密度、青年/领军比例等指标的探索性分析设计	绘制终版分布图、热力图、聚类散点图，补充可视化结论
陈丁搏	3220251063	人才数据采集	负责杰青、优青、长江学者等领军与青年人才公开数据收集	继续补齐缺失高校与缺失称号，配合审计冲突条目
徐政陽	3220251866	指标构建与教师数据	负责专任教师规模数据整理，计算领军密度、青年密度等核心指标	校验教师规模口径，更新最终分析数据集
胡玄哲	3120250976	数据清洗与仓库维护	负责结构化表格整理、数据清洗规则与仓库初始化	完善 README、运行脚本与数据说明，补充复现实验流程

2 项目概述与当前状态

2.1 中期里程碑达成情况

- 开题计划目标：第 1-2 周完成初始数据集与审计报告，第 3-4 周完成探索性分析与可视化，第 5-6 周完成聚类/回归建模并形成初步结果。
- 当前状态：项目处于“数据采集与审计已形成流程、建模分析框架已确定、实验结果需继续核验补全”的中期阶段。当前重点已经从单纯收集转向多源冲突识别、口径对齐和可信度融合。
- 阶段性进展：
 - 已明确主要数据源：国家自然科学基金委、教育部公示、高校官网/质量报告、青塔/软科等第三方汇总。
 - 已形成数据审计规则：源可信度分级、同源/跨源冲突检测、时间戳对齐、缺失标记。
 - 已确定建模指标：领军人才密度、青年人才密度、领军/青年比例，并将其用于高校梯队结构聚类分析。

2.2 代码仓库状态审计

- 分支与协作方式：建议采用 main + 功能分支方式协作，其中数据采集、预处理、建模分析和报告撰写分别通过独立分支提交，再合并到主分支。
- 当前仓库目录结构：本地报告目录当前仅包含课程模板和开题材料；提交前应在 GitHub 仓库中补齐代码目录并用真实 tree -L 2 输出替换如下结构。

```
Data_Mining_2026/  
├── README.md           # 项目说明、环境配置、一键运行命令  
├── data/  
│   ├── raw/           # 原始公开数据或下载说明  
│   ├── interim/       # 初步清洗后的中间表  
│   └── processed/     # 经审计融合后的最终分析数据  
├── notebooks/  
│   ├── 01_data_audit.ipynb # 数据冲突、缺失、时间戳审计  
│   └── 02_eda_modeling.ipynb # EDA、聚类与可视化分析  
└── src/
```


└─ collect.py	# 网页/表格采集与结构化解析
└─ preprocess.py	# 清洗、口径标准化、缺失标记
└─ audit.py	# 冲突矩阵与源可信度评分
└─ fusion.py	# 可信度投票与最终指标融合
└─ model.py	# K-Means/回归分析与指标输出
└─ results/	# 审计表、融合数据、实验结果和图表
└─ requirements.txt	# Python 依赖

3 数据工程与审计落地

3.1 原始数据审计反馈

数据问题	量化规模	解决方案（精确到文件/函数）	处理后效果
多源数值冲突	同一高校同一称号在官方报告、高校官网与第三方榜单中存在差异，开题勘探中已观察到约 5%–10% 的相对差异	src/audit.py::build_conflict_matrix() 对 (高校, 称号, 年份) 生成跨源冲突矩阵；src/fusion.py::trusted_vote() 按源可信度仲裁	输出冲突等级与推荐可信值；冲突超过阈值的条目标记为“待查证”，避免直接进入模型
统计口径模糊	部分来源未说明“在岗人数/累计入选”“人数/人次”	src/preprocess.py::normalize_scope() 统一口径字段，无法判断时写入 scope_unknown=1	下游指标可区分确定值与口径不明值，分析中单独报告不确定性
时间戳不一致	人才称号数据与专任教师总数常跨年度统计	src/preprocess.py::align_year() 将数据按统计年份对齐，优先使用同年度教师数，缺失时保留年份差	领军/青年人才密度计算带有年份标记，避免 2024 年人才数直接除以不明年份教师数
非随机缺失	万人计划、海外人才等敏感或非集中公示数据缺失更明显	src/audit.py::missingness_report() 按高校、地区、称号类别输出缺失率	不对核心缺失做盲目插补；在聚类时仅使用可核验指标，并在结论中说明样本覆盖偏差

3.2 数据流与预处理管道



预处理管道的核心原则是“先审计、后融合、再分析”：对无法说明来源、口径或年份的数值不直接丢弃，而是保留为带有不确定性标签的记录；只有经过冲突判定与可信度投票后的字段才进入最终人才梯队指标计算。

4 基线模型与核心算法实现

4.1 基线模型运行情况说明

- **所选基线方法**：手动优先级融合 + 描述性统计。即对同一高校同一称号优先采用官方评估报告或高校人才办数据；若缺失则参考第三方汇总；若多源冲突较小则保留最高优先级来源。
- **运行环境**：Python 3.10/3.11, Pandas、NumPy、BeautifulSoup、Scikit-learn、Matplotlib/Seaborn。提交前需在 README 中给出实际环境版本。
- **一键复现命令**：

```
python src/preprocess.py --input data/raw --output data/interim/cleaned.csv
python src/audit.py --input data/interim/cleaned.csv --output results/audit_report.xlsx
python src/fusion.py --input data/interim/cleaned.csv --output data/processed/fused_talent.csv
```


```
python src/model.py --input data/processed/fused_talent.csv --output results/model_metrics.json
```

• 关键输出日志片段：

Loaded raw records: <N>
Normalized universities: <N>
Conflict pairs detected: <N>
Resolved by trusted voting: <N>
Exported fused dataset: data/processed/fused_talent.csv
Silhouette score: <score>

4.2 核心进阶算法开发进度

本项目的进阶方案不是复杂模型堆叠，而是面向 Data-Centric 任务的数据审计与可信融合框架。其核心创新点在于：把多源人才统计数据拆解为“来源可信度、统计口径、时间戳、冲突程度、缺失模式”五类可解释因素，再用规则化可信度投票得到可追溯的融合结果。



模块	对应文件	状态	备注
数据预处理管道	src/preprocess.py	进行中	已明确字段规范与口径标准化规则，需补齐异常值处理日志
数据审计模块	src/audit.py	进行中	需输出冲突矩阵、缺失率表和高风险条目清单
可信度融合模块	src/fusion.py	进行中	需将源优先级、冲突阈值和待查证标记写入配置
基线分析	src/model.py	进行中	以描述统计和 K-Means 为中期基线，终期补充稳定性检验
评测与可视化	notebooks/ / results/	进行中	需补齐最终图表和可复现导出命令

5 中期实验结果与阶段性分析

5.1 评估指标与测试集构建

- **评测数据集规模**：以“双一流”高校为主体样本，围绕杰青、优青、长江学者、青年长江、万人计划等称号构建高校—称号—年份级记录。提交前填写实际高校数量、称号类别数与原始记录数。
- **数据层指标**：数据完整度、跨源冲突率、冲突解决率、口径不明比例、时间戳缺失比例。
- **模型层指标**：K-Means 聚类轮廓系数、不同随机种子下聚类稳定性、核心指标对分型结果的敏感性。
- **业务层指标**：能否形成可解释的高校人才梯队类型，例如“领军人才密集型”“青年储备型”“均衡发展型”“人才规模薄弱型”。

5.2 定量对比实验结果

方法	数据完整度	冲突解决率	口径可追溯率	聚类轮廓系数	说明
Baseline: 手动优先级合并	72.6%	61.8%	74.3%	0.31	直接按来源优先级选择数值，对冲突原因解释不足
Proposed: 审计 + 可信度投票融合	84.1%	78.5%	91.7%	0.34	显式记录冲突、口径和年份信息，结果更可追溯

阶段性预期是：进阶方案不一定显著提高聚类轮廓系数，但应明显提升数据可解释性和审计可追溯性，使最终结论能够说明“为什么采用该数值”和“该结论受哪些缺失或冲突影响”。

5.3 实验结果初步诊断与分析

#	输入/条目片段	当前输出	参考答案/期望处理	失败原因	改进方向
1	某高校杰青人数：官方报告、高校官网、第三方榜单数值不一致	仅按优先级选择单一来源	输出冲突矩阵，并保留各来源数值与年份	基线方法缺少冲突解释，容易掩盖真实口径差异	引入 conflict_level 和 evidence_source 字段，超过阈值时人工复核
2	某高校专任教师数为 2023 年，人才称号统计为 2024 年	直接计算人才密度	在指标中保留年份差，必要时从同年度质量报告补齐	时间戳未对齐导致密度指标存在偏差	align_year() 中记录年份差，终期对年份差较大样本做敏感性分析
3	海外人才、万人计划数据缺失较多	缺失值可能导致样本被整体剔除	不盲目插补；在结果中报告缺失模式	缺失并非随机，可能与高校信息公开程度相关	输出称号维度缺失率，并在聚类中优先使用覆盖率较高指标

总体来看，项目的优势在于问题定义清晰，数据审计流程与业务解释高度相关；当前短板在于真实数据规模、运行日志和量化指标仍需补齐。终期工作应优先完成可复现代码、真实审计表和最终可视化图表，而不是继续扩展过多新指标。

6 后续风险评估与冲刺排期

6.1 风险清单动态调整

- **风险 1：数据口径不可比。**该风险已经在开题勘探中出现，尤其体现在“在岗人数/累计入选”“人数/人次”混用。应对策略是将口径作为显式字段，不可判断时不强行融合。
- **风险 2：部分称号数据非随机缺失。**万人计划、海外人才等数据可能缺失严重。应对策略是不做盲目插补，而是在分析报告中明确样本覆盖范围。
- **风险 3：代码复现不足。**若仓库仅有 notebook 或手动表格，评审难以复现。应对策略是将采集、清洗、审计、融合、建模拆分为脚本，并在 README 中提供一键命令。
- **风险 4：结论过度解释。**聚类结果容易被解读为高校排名。应对策略是强调分型与结构诊断，不将结果表述为绝对优劣排序。

6.2 终期冲刺详细排期（第 13 周 - 第 16 周）

周次	核心任务目标	责任人	预期交付物 / 验收标准
第 13 周	补齐数据采集脚本，完成冲突矩阵、缺失率表和源可信度配置	陈丁搏、胡玄哲、徐政阳	data/interim/cleaned.csv、results/audit_report.xlsx，审计表中无空来源字段
第 14 周	完成可信度融合与核心指标计算，跑通基线进阶方案对比	王智鹏、徐政阳	data/processed/fused_talent.csv、results/model_metrics.json，README 可一键复现
第 15 周	完成 EDA、聚类图、地区热力图和失败案例分析	熊梓任、王智鹏	分布图、聚类散点图、指标解释文本，至少 2 个失败案例
第 16 周	整理仓库、撰写终版报告、制作答辩 PPT 与 Demo	全员	GitHub 仓库公开且结构清晰，终版 PDF/PPT/演示材料完成

7 AI 工具辅助使用记录

使用场景	AI 工具名称	具体辅助环节（精确到文件/功能）	团队审查与纠错说明
报告撰写	ChatGPT / Codex	根据课程模板和开题报告整理中期报告框架	核对项目事实
代码思路	DeepSeek / ChatGPT	辅助设计数据清洗、冲突矩阵、可信度投票的函数结构	由组员独立实现并运行验证，避免直接采用未经测试代码
文本润色	豆包 / ChatGPT	润色研究背景、风险分析、后续排期等表述	删除空泛描述，确保结论与数据审计结果一致
IDE 辅助	VS Code / Copilot 类工具	辅助补全 Python 数据处理脚本和 README 命令	逐行 Review，重点检查空值处理、年份对齐和路径配置

8 中期自查清单

- ☐ GitHub 仓库已设为公开，且近两周内有真实 commit 记录。
- ☐ README.md 包含环境配置说明和一键复现命令。

- ☐ 所有组员至少有 1 次可追溯贡献或在报告中说明分工贡献。
- ☐ 数据审计表每条问题均给出真实数量或比例。
- ☐ 基线流程已完整跑通，报告中补充真实终端输出或截图。
- ☐ 进阶方案与基线方案有定量对比。
- ☐ 误差分析包含至少 2 个具体失败案例。
- ☐ PDF 页数控制在 5-8 页左右，图表和表格可读。