

基于多源异构数据整合的“双一流”高校高层次人才梯队分析

开题报告

项目方向：复杂 Data-Centric 改进

团队成员：王智鹏（3120255027）、熊梓任（3120250948）、陈丁搏（3220251063）、徐政陽（3220251866）、胡玄哲（3120250976）

1. 问题定义

1.1 研究背景与动机

高层次人才（长江学者、国家杰出青年科学基金获得者、万人计划领军人才等）的规模与结构，是衡量高校核心竞争力的关键指标。然而，这些数据分散于国家自然科学基金委、教育部、中组部、高校官网等多个异构公开来源。各来源在统计口径（“在岗人数” vs “累计入选”、“人数” vs “人次”）、时间戳和数值上存在显著冲突。

现有第三方汇总报告（如青塔、软科）虽然提供了整理后的数据，但其口径和采集方法不透明，难以直接用于精准的梯队结构分析。直接使用任一单一来源或简单合并多源数据，都会引入不可忽略的系统性偏差。

因此，本项目的核心是攻克这一多源异构、高冲突人才数据的整合与审计难题，在此基础上分析“双一流”高校的领军与拔尖青年人才梯队结构，为教育政策评估和高校对标管理提供可靠的数据基础与分析洞察。

1.2 任务形式化

记高校集合为 $\mathbf{U}=u_1, u_2, \dots, u_n$ ，目标人才称号集合为 $\mathbf{T}$ ，公开数据源集合为 $\mathbf{S}=s_1, s_2, \dots, s_k$ 。每个数据源 s_j 为一个四元组 (u_i, t, v, meta) ，其中 v 为数值， meta 包含时间戳、口径说明等元信息。

核心约束： $\mathbf{S}$ 多以“人数”（非人名列表）形式提供；多源数据间存在数值矛盾、口径不明和系统性缺失。

项目输出：

1. 数据审计报告：各数据源间的冲突矩阵 $C(u_i, t, s_j, s_k)$ 及源可信度评分。

2. 经对齐融合的数据集：每个 ui 在每种称号 t 上的最可信人数 $w(ui,t)$ 。
3. 分析洞察：基于 w 计算的领军人才密度、青年人才密度、领军/青年比例，以及基于这些指标的高校聚类分型。

2. 数据来源证明与初步勘探

2.1 数据来源

数据项	来源	获取方式
杰青/优青名单	国家自然科学基金委官网	手动下载历年资助名单 PDF/Excel
长江学者/青年长江	教育部官网公示	手动下载历年公示名单
万人计划/海外人才	中组部/相关公示	公开公示信息+高校年度人才工作报告
专任教师总数	各高校《本科教学质量报告》/教育部《高等学校科技统计资料汇编》	官网下载报告 PDF
辅助验证	青塔、软科等第三方汇总报告	公开网页数据
高校特征数据	高校官网、所在城市统计年鉴	收集预算、所在地、优势学科等信息

2.2 初步数据勘探与核心挑战

我们进行了初步采集，已发现以下数据层面的核心挑战：

挑战类型	具体表现	示例
多源数值冲突	同一高校同一称号，不同来源数值不一致，相差 5 - 10%	基金委统计 125vs 青塔 131vs 高校官网 “120 余人”
统计口径模糊	不清楚数值是“累计入选”还是“在岗”、“人数”还是“人次”	多数来源只给出一个数字，未注明是否含已离职/去世学者
时间戳缺失	人才数据与专任教师数据的统计年份常不一致	杰青数据为 2024 年，专任教师数为 2023 年
非随机缺失	部分高校的数据缺失更严重，海外创新人才等敏感数据几乎不可得	部分高校仅能查到杰青/优青数据，万人计划、海外人才数据完全缺失

初步审计结论：必须建立一套透明的数据审计与融合规则，才能获得可用于分析的可靠数据集。

3. 初步方法与技术栈

3.1 基线方案

1. 数据采集：纯手动从各高校人才办页面和官方评估报告复制粘贴。
2. 数据融合：将数据源进行信任度分级，如《本科教学质量报告》为第一层级，半自动仲裁冲突。
3. 分析方法：描述性统计+简单相关分析。

3.2 核心进阶方案

模块 1：半自动化数据采集管道

1. 对结构化程度高的来源（如高校人才办公示表格），使用 Python+Pandas(pd.read_html)+BeautifulSoup 进行结构化抓取。
2. 对新闻类非结构化文本（如“我校新增杰青 5 人”），使用正则表达式进行关键词抽取。

模块 2：多源数据审计与“可信度投票”融合

1. 源可信度等级：预先设定优先级——官方评估报告>高校人才办官网“在岗人数”栏目>第三方汇总>年度新闻手动累加。
2. 一致性检验：若多个来源的数值差异 $\leq 10\%$ ，取最高优先级源的数值；若冲突 $>10\%$ ，标记为“待查证”，通过检索带精确日期和数字的黄金标准新闻（如“截至 2024 年 12 月，我校现有杰青 XX 人”）进行调停。
3. 缺失值处理：对确实无法获取的指标，不做盲目插补，而是在分析中明确标注“数据不可得”，并讨论其对结论的影响。
4. 审计输出：生成一份各数据源间的冲突矩阵，量化数据质量。

模块 3：基于清洗数据的分析与建模

1. 探索性分析：绘制领军密度、青年密度、领军/青年比例的分布图；使用热力图展示地域分布差异。
2. K-Means 聚类：基于“领军密度”和“青年密度”两个维度对高校分型，识别“重领军轻青年”、“青年储备充足”等梯队模式。
3. 可选关联分析：若数据允许，探索预算、所在地 GDP 等与人才密度的关系。

3.3 技术栈

- 1. 数据采集与清洗: Python(Pandas,NumPy,Requests,BeautifulSoup,re)
- 2. 可视化: Matplotlib,Seaborn,Plotly (地图可视化)
- 3. 建模: Scikit-learn(K-Means,LinearRegression 可选)
- 4. 协作与版本控制: Git,GitHub

4. 评估标准

4.1 数据层指标

- 1. 数据完整度: 实际收集到完整数据的高校数。
- 2. 冲突解决率: 被审计模块成功调停并给出可信值的冲突条目比例。

4.2 模型层指标

聚类轮廓系数: 衡量 K-Means 聚类结果的紧密度与分离度。

4.3 业务层指标

能否生成一份包含“数据审计摘要”、““双一流”高校人才梯队现状诊断”和“2-3 条可操作建议”的完整分析报告。

5. 时间规划与分工

阶段	时间	负责人	关键产出
数据采集与审计	第 1-2 周	陈丁搏、胡玄哲、徐政陽	初始数据集、数据审计报告
探索性分析与可视化	第 3-4 周	熊梓任	EDA 图表、初步分析结论
建模分析	第 5-6 周	王智鹏	聚类/回归模型、结果解读
报告撰写与答辩准备	第 7-8 周	全员	终版报告、PPT、GitHub 仓库

成员具体分工:

- 1. 陈丁搏、胡玄哲: 负责领军人才与拔尖青年人才数据收集, 整理成结构化表格 (不做去重, 同一人才不同称号分别计数)。
- 2. 徐政陽: 负责专任教师数据收集, 按高校汇总人才数据, 计算核心指标 (领军密度、青年密度、领军/青年比例), 输出最终分析数据集。
- 3. 熊梓任: 负责探索性数据分析与可视化, 绘制分布图、热力图、聚类散点图, 撰写初步分析结论。

4. 王智鹏：负责建模分析与报告撰写，选择合适方法（K-Means 聚类或回归分析），实现并调优模型，整合全组工作，完成项目报告和 PPT。

附：预期使用的 AI 工具 workbuddy. deepseek. 豆包. chatgpt. vscode 等

项目 github 仓库已初始化，包含 README.md 和 .gitignore，链接：

https://github.com/HUX3273/Data_Mining_2026